



VNiVERSiDAD
D SALAMANCA

SISTEMAS INTELIGENTES

ÁRBOLES DE DECISIÓN

— Aplicación al dataset Cleveland Heart Disease —

DIEGO FERNÁNDEZ SUTIL
MIGUEL BARRANQUERO DíEZ

MÁSTER EN INGENIERÍA INFORMÁTICA
MAYO, 2026

Índice

1. Introducción	3
2. Descripción del dataset	3
2.1. Origen y contexto	3
2.2. Estructura y atributos	3
2.3. Análisis exploratorio	3
3. Metodología	4
3.1. Preprocesado	4
3.2. Partición de datos	5
3.3. Construcción del árbol y problema del sobreajuste	5
3.4. Poda mediante limitación de complejidad	5
3.5. Selección del modelo final mediante validación cruzada	5
3.6. Métricas de evaluación	5
4. Resultados e interpretación	6
4.1. Comparación entre el árbol sin podar y el árbol podado	6
4.2. Visualización del sobreajuste según la profundidad	6
4.3. Configuración del modelo final	7
4.4. Estructura e interpretación del árbol	7
4.5. Importancia de los atributos	8
4.6. Evaluación detallada sobre el conjunto de prueba	9
5. Conclusiones	10
5.1. Sobre el funcionamiento del algoritmo	10
5.2. Limitaciones del trabajo	11
5.3. Posibles mejoras	11
5.4. Valoración final	11

1. Introducción

Este trabajo aborda la aplicación práctica del algoritmo de **árboles de decisión** sobre un conjunto de datos real, con el objetivo de obtener un modelo de clasificación, interpretarlo y extraer conclusiones sobre su utilidad y limitaciones.

Para esta práctica se ha seleccionado el dataset *Heart Disease (Cleveland)* del UCI Machine Learning Repository [2], un conjunto de datos clínicos ampliamente utilizado en la literatura sobre clasificación y diagnóstico asistido por aprendizaje automático.

El trabajo se ha desarrollado en Python utilizando la biblioteca `scikit-learn` [3] y se estructura como sigue: la Sección 2 describe el dataset; la Sección 3 detalla la metodología seguida; la Sección 4 presenta los resultados e interpretación del árbol obtenido; y la Sección 5 recoge las conclusiones del trabajo.

2. Descripción del dataset

2.1. Origen y contexto

El dataset *Heart Disease* fue donado al UCI Machine Learning Repository en julio de 1988 por Robert Detrano (V.A. Medical Center, Long Beach y Cleveland Clinic Foundation) [2]. Se trata de un conjunto de datos clínicos recopilados con el objetivo de predecir la presencia de **enfermedad coronaria** en pacientes a partir de variables fácilmente obtenibles en una exploración cardiológica rutinaria.

El repositorio original contiene cuatro bases de datos procedentes de hospitales de *Cleveland*, *Hungría*, *Suiza* y *Long Beach*. En la práctica, la mayor parte de la literatura utiliza únicamente el subconjunto de **Cleveland**, que es el más completo y el que emplearemos en este trabajo.

2.2. Estructura y atributos

El dataset Cleveland contiene **303 instancias** y, aunque la base original recogía 76 atributos por paciente, los autores seleccionaron 14 que demostraron mayor capacidad predictiva. La Tabla 1 resume estos atributos.

#	Nombre	Tipo	Descripción
1	age	Numérico	Edad en años (29–77)
2	sex	Binario	0 = mujer, 1 = hombre
3	cp	Categorico	Tipo de dolor torácico (1–4)
4	trestbps	Numérico	Tensión arterial en reposo (mmHg)
5	chol	Numérico	Colesterol sérico (mg/dl)
6	fbs	Binario	Glucemia en ayunas > 120 mg/dl
7	restecg	Categorico	Resultados del ECG en reposo (0–2)
8	thalach	Numérico	Frecuencia cardíaca máxima alcanzada
9	exang	Binario	Angina inducida por ejercicio
10	oldpeak	Numérico	Depresión del ST por ejercicio
11	slope	Categorico	Pendiente del segmento ST (1–3)
12	ca	Numérico	Vasos principales en fluoroscopia (0–3)
13	thal	Categorico	Talasemia: 3=normal, 6=fijo, 7=reversible
14	num	Categorico	Variable objetivo (0–4)

Tabla 1: Atributos del dataset Cleveland Heart Disease.

Los 13 primeros atributos son **predictores** y el último (**num**) es la **variable objetivo**, que codifica la severidad de la enfermedad coronaria diagnosticada angiográficamente en una escala de 0 (sin enfermedad) a 4 (afectación muy severa).

2.3. Análisis exploratorio

Un análisis exploratorio inicial revela varios aspectos relevantes:

Tamaño y completitud. El dataset contiene 303 instancias y presenta **6 valores faltantes** en total, distribuidos en dos atributos: 4 en `ca` y 2 en `thal`.

Distribución del target. La variable `num` presenta la siguiente distribución original:

Valor	Instancias	Significado
0	164 (54.1 %)	Sin enfermedad
1	55 (18.2 %)	Enfermedad leve
2	36 (11.9 %)	Enfermedad moderada
3	35 (11.6 %)	Enfermedad grave
4	13 (4.3 %)	Enfermedad muy grave

Tabla 2: Distribución de la variable objetivo `num`.

Sesgos observados. El dataset presenta un fuerte sesgo de género (68 % hombres, 32 % mujeres).

Estadísticos descriptivos. La Tabla 3 recoge los estadísticos descriptivos de los atributos numéricos.

Atributo	Media	Desv. std	Mín	Mediana	Máx
<code>age</code>	54.44	9.04	29	56	77
<code>trestbps</code>	131.69	17.60	94	130	200
<code>chol</code>	246.69	51.78	126	241	564
<code>thalach</code>	149.61	22.88	71	153	202
<code>oldpeak</code>	1.04	1.16	0	0.8	6.2

Tabla 3: Estadísticos descriptivos de los atributos numéricos.

3. Metodología

El flujo general consta de varias etapas: preprocesado, partición de los datos, construcción y poda del árbol mediante validación cruzada, y evaluación del modelo final sobre el conjunto de prueba. Todo el código se ha implementado en Python utilizando la biblioteca `scikit-learn` [3].

3.1. Preprocesado

Las decisiones de preprocesado aplicadas han sido las siguientes:

1. Tratamiento de valores faltantes. El dataset original contiene 6 instancias con valores faltantes (4 en `ca` y 2 en `thal`). Dado que representan menos del 2% del total y están dispersas entre clases, se ha optado por **eliminarlas**, quedando un conjunto final de **297 instancias**. Imputar únicamente 6 valores en variables tan informativas como `ca` y `thal` introduciría más ruido que la pérdida de información asociada a su eliminación.

2. Binarización del target. La variable objetivo `num` en su versión original toma valores 0–4, donde 0 indica ausencia de enfermedad y 1–4 representan grados crecientes de severidad. Las clases 1–4 están muy desequilibradas (entre 13 y 55 instancias). En lugar de tratar el problema como *multiclase* con clases minoritarias críticas, se ha agrupado todas las severidades positivas en una única clase, manteniendo un equilibrio adecuado (54.1 % sanos / 45.9 % enfermos).

Esta decisión está además respaldada por la propia documentación del repositorio UCI, que indica que la mayoría de experimentos con este dataset se han centrado en distinguir presencia (valores 1–4) frente a ausencia (valor 0) de enfermedad.

3. Codificación de variables categóricas. No se ha aplicado *one-hot encoding* a las variables categóricas (`cp`, `restecg`, `slope`, `thal`) porque los árboles de decisión de `scikit-learn` trabajan con *splits* numéricos sobre el propio valor codificado.

4. Escalado. No se ha aplicado normalización ni estandarización a los atributos numéricos.

3.2. Partición de datos

El conjunto de 297 instancias se ha dividido en **entrenamiento (75 %)** y **test (25 %)**, obteniendo 222 y 75 instancias respectivamente. La partición es **estratificada** (`stratify=y`) para preservar la proporción de clases en ambos subconjuntos, y se ha fijado una semilla aleatoria (`random_state=42`) para garantizar la reproducibilidad de los resultados.

3.3. Construcción del árbol y problema del sobreajuste

Los árboles de decisión presentan, como principal inconveniente, una **tendencia al sobreajuste** [1]: en ausencia de restricciones, el algoritmo continúa dividiendo nodos hasta que cada hoja contiene una sola clase, memorizando incluso el ruido del conjunto de entrenamiento.

Para ilustrar este fenómeno, en una primera fase se ha construido un **árbol sin restricciones** sobre el conjunto de entrenamiento. Este modelo de referencia, sin poda ni limitaciones, servirá como **línea base** y permitirá cuantificar el efecto de las técnicas de control de la complejidad que se aplican a continuación.

3.4. Poda mediante limitación de complejidad

Para mitigar el sobreajuste, se han explorado distintas configuraciones del árbol modificando los parámetros que controlan su complejidad. Los más relevantes son:

- **max_depth**: profundidad máxima del árbol. Limitar la profundidad impide que el árbol crezca indefinidamente, forzándolo a quedarse con las divisiones más informativas.
- **min_samples_split**: número mínimo de muestras necesarias en un nodo para considerar dividirlo. Valores altos evitan particiones basadas en muy pocos casos.
- **min_samples_leaf**: número mínimo de muestras que debe contener cada hoja del árbol. Refuerza la restricción anterior.
- **criterion**: función de impureza utilizada para evaluar las particiones; pueden emplearse el índice de Gini o la entropía de Shannon.

3.5. Selección del modelo final mediante validación cruzada

La validación cruzada divide el conjunto de entrenamiento en 5 bloques iguales y entrena el modelo 5 veces, usando en cada iteración 4 bloques para entrenar y el restante para validar; la puntuación final es la media de las 5. Este procedimiento ofrece una estimación mucho más estable de cómo generalizará el modelo que un único *split* interno.

La métrica utilizada para comparar configuraciones ha sido la **precisión** (*accuracy*) media obtenida en la validación cruzada. Una vez identificada la mejor configuración, se ha entrenado el modelo final sobre los 222 ejemplos de entrenamiento utilizando esos parámetros, y se ha evaluado por última vez sobre los 75 ejemplos del conjunto de prueba.

3.6. Métricas de evaluación

Aunque la precisión es la métrica más intuitiva, en un problema clínico conviene reportar varias métricas complementarias:

- **Precisión global** (*accuracy*): proporción de aciertos sobre el total.
- **Matriz de confusión**: tabla cruzada predicción vs realidad, que muestra los aciertos y los dos tipos de errores (falsos positivos y falsos negativos).
- **Sensibilidad** (*recall* de la clase “Enfermo”): proporción de enfermos reales correctamente identificados. Es la métrica más crítica en un contexto médico, ya que cuantifica los casos en los que un paciente enfermo pasaría desapercibido.
- **Especificidad** (*recall* de la clase “Sano”): proporción de sanos correctamente identificados.

4. Resultados e interpretación

4.1. Comparación entre el árbol sin podar y el árbol podado

La primera fase del experimento consistió en construir un árbol sin ninguna restricción sobre el conjunto de entrenamiento, con el objetivo de evidenciar el problema del sobreajuste. La Tabla 4 resume los resultados obtenidos por los dos modelos.

	Sin podar	Podado
Profundidad del árbol	8	5
Número de hojas	34	19
Accuracy en entrenamiento	100 %	93 %
Accuracy en prueba	76 %	76 %
Gap entrenamiento–prueba	24 puntos	17 puntos

Tabla 4: Comparación entre el árbol sin podar y el árbol podado.

El árbol sin podar alcanza el 100 % de precisión sobre el conjunto de entrenamiento, lo que indica que ha memorizado completamente los datos vistos. Sin embargo, su rendimiento sobre el conjunto de prueba es solo del 76 %: el modelo no generaliza el conocimiento aprendido. Esta diferencia de 24 puntos entre entrenamiento y prueba es debido a la **característica del sobreajuste**.

El árbol podado, por su parte, mantiene una precisión de prueba similar (76 %) pero con una complejidad mucho menor: la mitad de hojas y tres niveles menos de profundidad.

4.2. Visualización del sobreajuste según la profundidad

La Figura 1 muestra cómo evolucionan la precisión de entrenamiento y la de prueba a medida que aumenta la profundidad máxima permitida del árbol.




Figura 1: Evolución de la precisión sobre entrenamiento y prueba en función de la profundidad máxima.

La gráfica ilustra el comportamiento típico del sobreajuste:

- La precisión de entrenamiento (azul) crece de forma monótona y alcanza el 100 % a partir de profundidad 8. A partir de ese punto, el árbol simplemente *memoriza* todos los ejemplos vistos.
- La precisión de prueba (rojo) se mantiene en una franja estrecha entre el 70 % y el 76 %, prácticamente independiente de la profundidad.

4.3. Configuración del modelo final

La validación cruzada seleccionó la siguiente configuración como óptima:

- `criterion = entropy` (función de impureza basada en entropía de Shannon)
- `max_depth = 5`
- `min_samples_split = 2`
- `min_samples_leaf = 1`

Con esta configuración, el modelo presenta una precisión media en validación cruzada del **82.9 %** sobre el conjunto de entrenamiento, y una precisión final del **76.0 %** sobre el conjunto de prueba.

4.4. Estructura e interpretación del árbol

La Figura 2 muestra el árbol de decisión final.




Figura 2: Árbol de decisión final obtenido tras la poda.

El árbol parte el conjunto de datos según la variable **cp** (tipo de dolor torácico), con el corte $cp \leq 3.5$. Esto separa a los pacientes en dos grandes grupos:

- **Pacientes con dolor torácico** (tipos 1-3: angina típica, atípica o no anginoso): 114 pacientes, de los cuales 90 están sanos y 24 enfermos. La mayoría **no tiene** enfermedad coronaria.
- **Pacientes asintomáticos** (tipo 4): 108 pacientes, de los cuales 78 están enfermos y solo 30 sanos. La mayoría **sí tiene** enfermedad coronaria.

Segundo nivel: ramificación según el contexto. A partir del primer nivel, el árbol utiliza diferentes variables según la rama:

- En la rama de **pacientes con dolor torácico**, el siguiente split es $oldpeak \leq 2.45$. Si la depresión es leve, la mayoría de pacientes está sana; si es alta, el diagnóstico se invierte.
- En la rama de **pacientes asintomáticos**, el siguiente split es $ca \leq 0.5$. Tener al menos un vaso afectado es un fuerte indicador de enfermedad.

Niveles inferiores. Los niveles 3 a 5 introducen splits adicionales sobre **age**, **chol**, **trestbps**, **thal** y **sex**, que refinan la clasificación en función del perfil específico del paciente. Algunas hojas son completamente puras (todas las muestras del mismo grupo) mientras que otras contienen mezclas, reflejando casos clínicamente ambiguos.

4.5. Importancia de los atributos

La Figura 3 presenta la importancia relativa de cada atributo, calculada como la suma ponderada de la reducción de entropía aportada por cada variable en todos sus splits del árbol.




Figura 3: Importancia relativa de los atributos en el árbol final.

4.6. Evaluación detallada sobre el conjunto de prueba

Matriz de confusión. La Figura 4 muestra la matriz de confusión sobre las 75 instancias del conjunto de prueba.




Figura 4: Matriz de confusión sobre el conjunto de prueba.

De los 40 pacientes sanos reales, el modelo clasifica correctamente a 34 (verdaderos negativos) y se equivoca en 6 (falsos positivos). De los 35 pacientes enfermos reales, acierta en 23 (verdaderos positivos) pero falla en 12 (falsos negativos).

Análisis por clase. La Tabla 5 recoge las métricas relevantes del modelo.

Métrica	Valor
Accuracy global	76.0 %
Sensibilidad (recall enfermo)	65.7 %
Especificidad (recall sano)	85.0 %
Precisión (clase enfermo)	79.3 %
F1-score (clase enfermo)	71.9 %

Tabla 5: Métricas del modelo final sobre el conjunto de prueba.

El modelo identifica mejor a los sanos (especificidad 85 %) que a los enfermos (sensibilidad 66 %). Dicho de otro modo: aproximadamente **1 de cada 3 pacientes enfermos pasa desapercibido** para el modelo. En un contexto médico, este sesgo hacia los falsos negativos es la limitación más relevante del clasificador, ya que estos errores tienen consecuencias clínicas mucho más graves que los falsos positivos: un paciente diagnosticado erróneamente como sano podría no recibir el tratamiento que necesita.

5. Conclusiones

La aplicación del algoritmo de árboles de decisión sobre el dataset *Heart Disease (Cleveland)* ha permitido construir un modelo de clasificación binaria que predice la presencia o ausencia de enfermedad coronaria con una precisión del 76 % sobre el conjunto de prueba. A continuación se recogen las principales conclusiones extraídas del trabajo.

5.1. Sobre el funcionamiento del algoritmo

La poda es imprescindible. El árbol sin restricciones sobreajusta de forma evidente, alcanzando un 100 % de precisión en entrenamiento frente al 76 % en prueba (un *gap* de 24 puntos). Tras aplicar las técnicas de poda mediante limitación de la profundidad y del número mínimo de muestras por nodo, el árbol resultante mantiene la misma precisión de prueba pero con la mitad de hojas, tres niveles menos de profundidad y un *gap* entrenamiento-prueba significativamente menor. Este resultado confirma que, en problemas reales con datos ruidosos, la complejidad del modelo no se traduce automáticamente en mejor rendimiento.

Selección automática de atributos. El algoritmo elige los atributos más informativos y descarta los redundantes. En este trabajo, cuatro de las trece variables disponibles (**exang**, **restecg**, **lbs** y **slope**) recibieron importancia cero, no por ser inútiles, sino porque su información ya estaba capturada por otras variables correlacionadas. Esta limitación es conocida: los árboles de decisión tienden a elegir una única variable de cada grupo correlacionado, dando una falsa impresión de que las demás son irrelevantes.

El árbol aprende reglas clínicamente coherentes. La estructura del árbol obtenido refleja conocimiento médico real. La variable más informativa resulta ser el tipo de dolor torácico (**cp**), con la observación contraintuitiva de que los pacientes asintomáticos son los que con más frecuencia tienen enfermedad coronaria. Los atributos más relevantes en el modelo (**cp**, **age**, **ca**, **chol**, **oldpeak**) coinciden con los factores de riesgo clásicos en cardiología, lo que aporta plausibilidad al modelo más allá de las métricas numéricas.

El error tiene un patrón preocupante. El modelo identifica mejor a los pacientes sanos (85 % de especificidad) que a los enfermos (66 % de sensibilidad). En la práctica, esto significa que aproximadamente **uno de cada tres enfermos reales pasa desapercibido**. En un contexto médico, los falsos negativos son mucho más graves que los falsos positivos: un paciente diagnosticado erróneamente como sano podría no recibir el tratamiento que necesita. Este sesgo es la limitación más importante del modelo y debería tenerse en cuenta.

5.2. Limitaciones del trabajo

- **Tamaño del dataset.** Con 297 instancias tras el preprocesado, el dataset es modesto.
- **Origen único de los datos.** Todos los registros proceden de una única institución (Cleveland Clinic) y de los años 80.
- **Sesgo de género.** El dataset contiene un 68 % de hombres frente a un 32 % de mujeres.

5.3. Posibles mejoras

A modo de orientación para trabajos futuros, las siguientes estrategias podrían mejorar los resultados obtenidos:

- **Métodos de ensemble** como *Random Forest* o *Gradient Boosting*, que combinan múltiples árboles y suelen alcanzar precisiones del 85 %–90 % en este dataset. Pierden parte de la interpretabilidad pero ganan robustez.
- **Ampliación del dataset** combinando las cuatro bases del repositorio UCI (Cleveland, Hungría, Suiza y Long Beach), lo que aumentaría el tamaño a casi 900 instancias a costa de un preprocesado más complejo por la presencia de más valores faltantes.

5.4. Valoración final

El trabajo ha permitido comprobar de primera mano el funcionamiento de los árboles de decisión sobre un problema realista, observando tanto sus virtudes (interpretabilidad, simplicidad, capacidad de selección automática de variables) como sus limitaciones (sobreajuste si no se controla, sesgo hacia variables correlacionadas, frontera de decisión limitada). El modelo resultante alcanza un rendimiento consistente con la literatura publicada sobre este dataset y produce reglas con sentido clínico, si bien sus errores presentan un patrón que sería necesario corregir antes de plantear cualquier aplicación práctica.

Referencias

- [1] Juan Alberto García Esteban. Aprendizaje: Modelos de Regresión y Clasificación. Transparencias de la asignatura Sistemas Inteligentes, Máster Universitario en Ingeniería Informática, Universidad de Salamanca, 2025.
- [2] Andras Janosi, William Steinbrunn, Matthias Pfisterer, and Robert Detrano. Heart Disease. UCI Machine Learning Repository, 1989. DOI: 10.24432/C52P4X.
- [3] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.